

# Método iterativo para solução de sistemas lineares

## Gradientes e Gradientes Conjugados

Silvia Maria Pereira Grandi dos Santos

USP - São Carlos/SP

Outubro 2008

# Roteiro

- ▶ Motivação;
- ▶ Processos de Relaxação;
- ▶ Estudo do caso  $f(x) = \frac{1}{2}x^T Ax - b^T x + x$ ;
- ▶ Método dos Gradientes;
- ▶ Direção Conjugada;
- ▶ Método dos Gradientes Conjugados;
- ▶ Exemplo resolvido.

# Motivação

Considere o sistema linear  $Ax = b$ . Deseja-se encontrar a solução  $x$  desse sistema.

Muitas vezes, usar Métodos Exatos para encontrar a solução desse sistema é tão eficiente quanto usar Métodos Iterativos, mas a situação pode se complicar quando usamos Métodos Exatos em sistemas cuja matriz dos coeficientes,  $A$ , é uma matriz esparsa (cheia de zeros).

O Método dos Gradientes é utilizado quando a matriz  $A$  é simétrica definida positiva.

# Processos de Relaxação

- ▶ Dado um sistema  $Ax = b$  e um ponto para a aproximação inicial  $x^{(0)}$  da solução do sistema, queremos reduzir o resíduo dado por  $r^{(0)} = b - Ax^{(0)}$  até que este resíduo seja nulo.
- ▶ Para que o resíduo diminua, tomamos uma direção  $v$  e corrigimos  $x^{(0)}$  nesta direção, ou seja,  $x^{(1)} = x^{(0)} + \lambda \vec{v}$  de forma que  $r^{(1)} = b - Ax^{(1)} < r^{(0)}$ .
- ▶ Dessa forma, construímos uma sequência  $\{x^{(k)}\}$  que converge para a solução do sistema  $Ax = b$ , pois estamos considerando que o resíduo diminua em cada passo do processo iterativo, ou seja,  $r^{(k+1)} < r^{(k)}$ .
- ▶ Quando  $k \rightarrow \infty$  temos  $r^{(k)} \rightarrow 0$  e, dessa forma,  $Ax^{(k)} \rightarrow b$  e  $x^{(k)}$  é uma aproximação para a solução do sistema dado  $Ax = b$ .

## Estudo de um caso específico

Para o estudo da função  $f(x) = \frac{1}{2}x^T Ax - b^T x + c$  consideremos as seguintes notações:

- ▶  $x^T y$  representa o produto escalar de  $x$  com  $y$  no espaço  $\mathbb{R}^n$ , assim


$$x^T y = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \sum_{i=1}^n x_i y_i$$

- ▶ Se  $x$  e  $y$  são vetores ortogonais, então  $x^T y = 0$
- ▶  $A$  é uma matriz definida positiva se, para todo vetor  $x$  não nulo, tem-se  $x^T Ax > 0$
- ▶ Lembre-se que  $(AB)^T = B^T A^T$ .

## Estudo de um caso específico

Considere  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  em que  $f(x) = \frac{1}{2}x^T A x - b^T x + c$ ,  $A$  é uma matrix  $n \times n$ ,  $b$  e  $x$  são vetores  $n \times 1$  e  $c$  uma constante.

Sejam  $A = \begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix}$ ,  $b = \begin{bmatrix} 2 \\ -8 \end{bmatrix}$  e  $c = 0$ . Nestas condições, o gráfico da função  $f$  pode ser visto na Figura 6.



O ponto de mínimo de  $f(x)$  neste caso é o ponto  $(2, -2)$ .

## Estudo de um caso específico

É possível mostrar que o ponto de mínimo de  $f(x)$  é a solução do sistema  $Ax = b$ . De fato, sabemos que o ponto de mínimo de  $f(x)$  é um ponto crítico, ou seja,  $f'(x) = \nabla f(x) = 0$ .

Mas  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ;  $f(x) = \frac{1}{2} \sum_{i,j=1}^n a_{ij}x_i x_j - \sum_{i=1}^n b_i x_i + c$ . Assim

$$\nabla f(x) = \begin{bmatrix} \frac{\partial}{\partial x_1} f(x) \\ \frac{\partial}{\partial x_2} f(x) \\ \vdots \\ \frac{\partial}{\partial x_n} f(x) \end{bmatrix} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots a_{1n}x_n - b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots a_{2n}x_n - b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots a_{nn}x_n - b_n \end{bmatrix} = Ax - b$$

Fazendo  $\nabla f(x) = 0$  temos  $Ax - b = 0 \Rightarrow Ax = b$ , ou seja, o ponto crítico de  $f(x)$  é o ponto  $x$  tal que  $Ax = b$ . Nos resta saber se  $x$ ;  $Ax = b$  é de mínimo ou de máximo.

## Estudo de um caso específico

Sabemos que um ponto  $x$  é ponto de mínimo de  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  se  $J(f)$  é positiva definida.


$$\begin{aligned} \text{Como } J &= \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \vdots & & & \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix} \\ &= \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & & & \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} = A \end{aligned}$$

e  $A$  é uma matriz positiva definida por hipótese, segue **o ponto  $x$  tal que  $Ax = b$  é ponto de mínimo de  $f(x)$** . Dessa forma, se encontrarmos o ponto de mínimo de  $f(x)$  encontramos a solução do sistema  $Ax = b$ .



## Estudo de um caso específico

Sabemos que  $\nabla f(x)$ , num dado ponto  $x$ , aponta a direção de maior crescimento da função  $f$ .




# Método dos Gradientes

Dada uma aproximação inicial  $x^{(0)}$  para a solução do sistema  $Ax = b$ , é seria natural pensarmos em tomar a direção oposta a  $\nabla f(x)$  para a correção de  $x^{(0)}$ , pois  $-\nabla f(x)$  aponta na direção que  $f$  decresce mais rapidamente (o ponto de mínimo de  $f$  é a solução do sistema  $Ax = b$ ).

Pelos cálculos feitos anteriormente, sabemos que  $-\nabla f(x^{(i)}) = b - Ax^{(i)} = r^{(i)}$ .

Dessa forma, tomando  $x^{(0)} = (-2, -2)$ , sabemos em qual direção caminhar, mas não sabemos o quanto caminhar.

# Método dos Gradientes



# Método dos Gradientes

Como  $x^{(1)} = x^{(0)} + \lambda r^{(0)}$  e  $\lambda$  minimiza  $f(x^{(1)})$  quando a derivada direcional  $\frac{\partial f(x^{(1)})}{\partial \lambda} = 0$ .

$$\text{Mas } \frac{\partial f(x^{(1)})}{\partial \lambda} = \left( f'(x^{(1)}) \right)^T \frac{\partial x^{(1)}}{\partial \lambda} = \left( f'(x^{(1)}) \right)^T r^{(0)}.$$

Igualando essa expressão a zero temos  $\left( f'(x^{(1)}) \right)^T r^{(0)} = 0$  que nos sugere que  $\lambda$  será escolhido de forma que  $r^{(0)}$  e  $f'(x^{(1)})$  sejam ortogonais.

Para determinar  $\lambda$  usamos o fato de  $f'(x^{(1)}) = -r^{(1)}$ . Dessa forma, teremos

# Método dos Gradientes

$$(r^{(1)})^T r^{(0)} = 0 \quad \text{Substituindo } r^{(1)} \text{ nessa expressão}$$

$$(b - Ax^{(1)})^T r^{(0)} = 0 \quad \text{Como } x^{(1)} = x^{(0)} + \lambda r^{(0)} \text{ temos}$$

$$(b - A(x^{(0)} + \lambda r^{(0)}))^T r^{(0)} = 0$$

$$(b - Ax^{(0)})^T r^{(0)} - \lambda (Ar^{(0)})^T r^{(0)} = 0$$

$$(b - Ax^{(0)})^T r^{(0)} = \lambda (Ar^{(0)})^T r^{(0)}$$

$$(r^{(0)})^T r^{(0)} = \lambda (r^{(0)})^T Ar^{(0)}$$

Logo

$$\lambda = \frac{(r^{(0)})^T r^{(0)}}{(r^{(0)})^T Ar^{(0)}}$$

# Método dos Gradientes

Colocando todas essas informações juntas, temos

dada uma aproximação inicial  $x^{(0)}$  para a solução do sistema  $Ax = b$ , o processo iterativo, conhecido como **Método dos Gradientes**, é dado por


$$\blacktriangleright r^{(i)} = b - Ax^{(i)}$$

$$\blacktriangleright \lambda^{(i)} = \frac{(r^{(0)})^T r^{(0)}}{(r^{(0)})^T A r^{(0)}}$$

$$\blacktriangleright x^{(i+1)} = x^{(i)} + \lambda^{(i)} r^{(i)}$$

# Método dos Gradientes

Intuitivamente, temos



# Método dos Gradientes

Exemplo: Usando o Método dos Gradientes, obtenha uma solução aproximada para  $\begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix} x = \begin{bmatrix} 5 \\ 4 \end{bmatrix}$  com  $x^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$  e  $\epsilon = 10^{-1}$ .

Abrir arquivo Exemplo1.xls e arquivo Exemplo1.mws



# Método dos Gradientes Conjugados

## **Método dos Gradientes Conjugados**

# Método dos Gradientes Conjugados


É possível, no Método dos Gradientes, uma direção que está sendo adotada na iteração  $i$  ter sido usada em iterações anteriores, como pode ser visto na Figura 15.

Para evitar que se tome várias vezes uma mesma direção  $r^{(i)}$  para a correção de  $x^{(i)}$ , o Método dos Gradientes Conjugados propõe uma modificação no Método dos Gradientes.

O Método dos Gradientes Conjugados sugere que, dada uma aproximação inicial  $x^{(0)}$  para o sistema  $n \times n$ ,  $Ax = b$ , tomemos um conjunto de direções conjugadas  $\{d_0, d_1, \dots, d_{n-1}\}$  e em até  $n$  iterações, teremos encontrado uma aproximação satisfatória para a solução do sistema.

Dois vetores  $x$  e  $y$  são conjugados se  $x^T Ay = y^T Ax = 0$ .

# Método dos Gradientes Conjugados



# Método dos Gradientes Conjugados

Dado  $x^{(0)}$ , faça  $d^0 = r^0 = b - Ax$  e  $x^{(1)}$  será obtido fazendo  $x^{(1)} = x^{(0)} + \lambda^{(0)} d^{(0)}$ .

Para obter o tamanho do passo  $\lambda^{(0)}$ , procedemos como no caso do Método dos Gradientes:

$$\frac{d(f(x^{(1)}))}{d\lambda} = f'(x^{(1)})^T \frac{dx^{(1)}}{d\lambda} = -r^{(1)T} d^{(0)}.$$

Como queremos que  $\lambda$  minimize  $f(x^{(1)})$ , fazemos

$$r^{(1)T} d^{(0)} = 0 \rightarrow d^{(0)T} r^{(1)} = 0 \rightarrow d^{(0)T} (b - Ax^{(1)}) = 0$$

Substituindo  $x^{(1)}$  nessa expressão concluímos que

$$\lambda^{(0)} = \frac{r^{(0)T} r^{(0)}}{d^{(0)T} A d^{(0)}}$$

# Método dos Gradientes Conjugados

Para que  $r^{(1)} = r^{(0)} - \lambda^{(0)} Ad^{(0)}$  seja ortogonal à nova direção  $d^{(1)} = r^{(1)} + \beta^{(1)} d^{(0)}$  é preciso escolher um valor para  $\beta^{(1)}$  conveniente. Assim

$$r^{(1)T} d^{(1)} = 0 \quad \rightarrow \quad \left( r^{(0)} - \frac{r^{(0)T} r^{(0)}}{d^{(0)T} A d^{(0)}} A d^{(0)} \right)^T (r^{(1)} + \beta^{(1)} d^{(0)}) = 0$$

$$r^{(0)T} r^{(1)} + \beta^{(1)} r^{(0)T} d^{(0)} - d^{(0)T} A \frac{r^{(0)T} r^{(0)}}{d^{(0)T} A d^{(0)}} r^{(1)} - \beta^{(1)} d^{(0)T} A \frac{r^{(0)T} r^{(0)}}{d^{(0)T} A d^{(0)}} d^{(0)} = 0$$

$$\text{Simplificando temos } \beta^{(1)} = -\frac{d^{(0)T} A r^{(1)}}{d^{(0)T} A d^{(0)}} = -\frac{r^{(1)T} A d^{(0)}}{d^{(0)T} A d^{(0)}}$$

Assim a nova direção é dada por  $d^{(1)} = r^{(1)} + \beta^{(1)} d^{(0)}$

# Método dos Gradientes Conjugados

Podemos resumir o Método dos Gradientes Conjugados por, dado  $x^{(0)}$  inicial

- ▶  $d^{(0)} = r^{(0)} = b - Ax^{(0)}$

- ▶ Para  $i = 0, 1, \dots$

- ▶  $\lambda^{(i)} = \frac{r^{(i)T} r^{(i)}}{d^{(i)T} A d^{(i)}}$

- ▶  $x^{(i+1)} = x^{(i)} + \lambda^{(i)} d^{(i)}$

- ▶  $r^{(i+1)} = r^{(i)} - \lambda^{(i)} A d^{(i)}$

- ▶  $\beta^{(i+1)} = -\frac{r^{(i+1)T} A d^{(i)}}{d^{(i)T} A d^{(i)}}$

- ▶  $d^{(i+1)} = r^{(i+1)} + \beta^{(i+1)} d^{(i)}$

# Método dos Gradientes Conjugados

Podemos simplificar um pouco mais a expressão de  $\beta^{(i+1)}$  considerando  $r^{(i+1)} = r^{(i)} - \lambda^{(i)} Ad^{(i)}$ , pois dessa forma temos

$$Ad^{(i)} = -\frac{1}{\lambda^{(i)}} (r^{(i+1)} - r^{(i)})$$

Fazendo  $r^{(i+1)} Ad^{(i)}$  e  $d^{(i)T} Ad^{(i)}$  temos

$$r^{(i+1)T} Ad^{(i)} = -\frac{1}{\lambda^{(i)}} (r^{(i+1)T} r^{(i+1)} - r^{(i+1)T} r^{(i)}) = -\frac{1}{\lambda^{(i)}} (r^{(i+1)T} r^{(i+1)})$$

e

$$d^{(i)T} Ad^{(i)} = -\frac{1}{\lambda^{(i)}} (d^{(i)T} r^{(i+1)} - d^{(i)T} r^{(i)}) = -\frac{1}{\lambda^{(i)}} (-d^{(i)T} r^{(i)}) = \frac{1}{\lambda^{(i)}} d^{(i)T} r^{(i)}$$

# Método dos Gradientes Conjugados

Substituindo  $r^{(i+1)T}Ad^{(i)} = -\frac{1}{\lambda^{(i)}} (r^{(i+1)T}r^{(i+1)})$  e

$$d^{(i)T}Ad^{(i)} = \frac{1}{\lambda^{(i)}}d^{(i)T}r^{(i)} \quad \text{em} \quad \beta^{(i+1)} \text{ temos}$$

$$\beta^{(i+1)} = -\frac{-\frac{1}{\lambda^{(i)}} (r^{(i+1)T}r^{(i+1)})}{\frac{1}{\lambda^{(i)}}d^{(i)T}r^{(i)}} = \frac{r^{(i+1)T}r^{(i+1)}}{d^{(i)T}r^{(i)}} = \frac{r^{(i+1)T}r^{(i+1)}}{r^{(i)T}r^{(i)}}$$



# Método dos Gradientes Conjugados

Dessa forma, dado  $x^{(0)}$  uma aproximação inicial do sistema  $Ax = b$ , o Método dos Gradientes Conjugados é dado por

- ▶  $d^{(0)} = r^{(0)} = b - Ax^{(0)}$

- ▶ Para  $i = 0, 1, \dots$

- ▶  $\lambda^{(i)} = \frac{r^{(i)T} r^{(i)}}{d^{(i)T} A d^{(i)}}$


- ▶  $x^{(i+1)} = x^{(i)} + \lambda^{(i)} d^{(i)}$

- ▶  $r^{(i+1)} = r^{(i)} - \lambda^{(i)} A d^{(i)}$

- ▶  $\beta^{(i+1)} = \frac{r^{(i+1)T} r^{(i+1)}}{r^{(i)T} r^{(i)}}$

- ▶  $d^{(i+1)} = r^{(i+1)} + \beta^{(i+1)} d^{(i)}$

# Método dos Gradientes Conjugados



# Método dos Gradientes Conjugados

**Exemplo:** Obtenha uma solução aproximada para o sistema

$$\begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix} x = \begin{bmatrix} 5 \\ 4 \end{bmatrix} \text{ com } x^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \text{ e } \epsilon = 10^{-1}.$$

Abrir arquivo Exemplo2.xls e arquivo Exemplo2.mws

# Referências

- ▶ Shewchuk, J R. *An Introduction to the Conjugate Gradient Method Without the Agonizing Pain* Edition 1 $\frac{1}{4}$ . School of Computer Science Carnegie Mellon University Pittsburgh. PA, 1994.
- ▶ Franco, N B. *Cálculo Numérico*. Editora: Pearson / Prentice Hal. 2006.
- ▶ Todas as figuras (exceto a primeira) foram extraídas de Shewchuk, 1994.